



Bundesministerium für Bildung und Forschung



- openHPI: ChatGPT: Was bedeutet generative KI für unsere Gesellschaft? -

# Copyright der Trainingsdaten

Johannes Hötter Christian Warmuth

### Wo kommen Trainingsdaten her?

ARTIFICIAL INTELLIGENCE / TECH / LAW

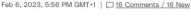
### Getty Images sues Al art generator Stable Diffusion in the US for copyright infringement





Getty Images has filed a case against Stability AI, alleging that the company copied 12 million images to train its Al model 'without permission ... or compensation.'

By James Vincent, a senior reporter who has covered Al. robotics, and more for eight years at The Verge.



An illustration from Gettu Images' lawsuit, showing an original photograph and a similar image (complete with Gettu Images watermark) generated bu Stable Diffusion. Image: Getty Images











#### Copyright der **Trainingsdaten**

Johannes Hötter, Christian Warmuth

openHPI

### Wo kommen Trainingsdaten her?













#### Copyright der Trainingsdaten

Johannes Hötter, Christian Warmuth

openHPI

### Wie gehen die Provider mit den Daten um?



Research - Product - Developers - Safety Company -

#### 3. Content

(a) Your Content. You may provide input to the Services ("Input"), and receive output generated and returned by the Services based on the Input ("Output"). Input and Output are collectively "Content." As between the parties and to the extent permitted by applicable law, you own all Input. Subject to your compliance with these Terms, OpenAl hereby assigns to you all its right, title and interest in and to Output. This means you can use Content for any purpose, including commercial purposes such as sale or publication, if you comply with these Terms. OpenAl may use Content to provide and maintain the Services, comply with applicable law, and enforce our policies. You are responsible for Content, including for ensuring that it does not violate any applicable law or these Terms.

(b) Similarity of Content. Due to the nature of machine learning, Output may not be unique across users and the Services may generate the same or similar output for OpenAI or a third party. For example, you may provide input to a model such as "What color is the sky?" and receive output such as "The sky is blue." Other users may also ask similar questions and receive the same response. Responses that are requested by and generated for other users are not considered your Content.

(c) Use of Content to Improve Services. We do not use Content that you provide to or receive from our API ("API Content") to develop or improve our Services. We may use Content from Services other than our API ("Non-API Content") to help develop and improve our Services. You can read more here about <a href="https://www.non-API Content may be">https://www.non-API Content may be</a> used to improve model performance. If you do not want your Non-API Content used to improve Services, you can opt out by filling out <a href="https://www.non-API Content to see that in some cases this may limit the ability of our Services to better address your specific use case.">https://www.non-API Content to see that in some cases this may limit the ability of our Services to better address your specific use case.





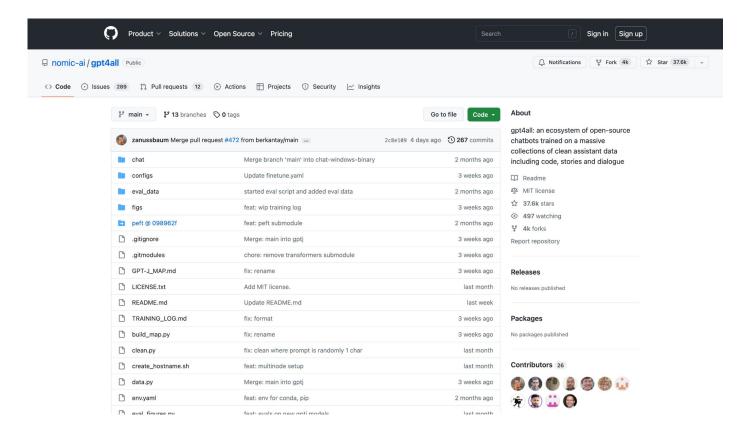


#### Copyright der Trainingsdaten

Johannes Hötter, Christian Warmuth

openHPI

### Erneutes Thema: Open-Source für Self-Hosting







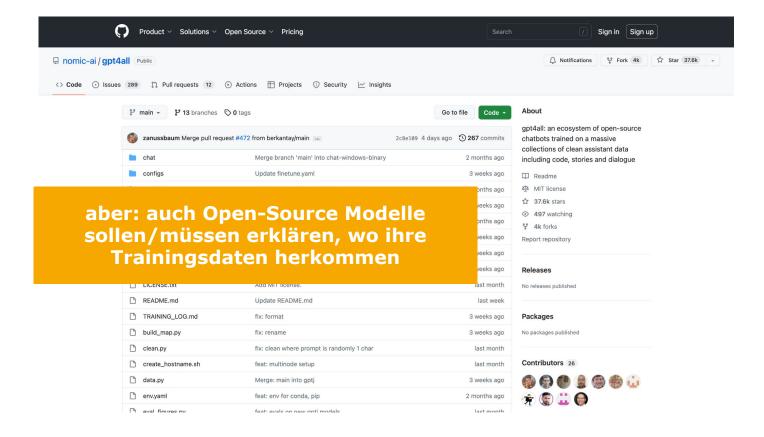


#### Copyright der Trainingsdaten

Johannes Hötter, Christian Warmuth

openHPI

### Erneutes Thema: Open-Source für Self-Hosting









#### Copyright der Trainingsdaten

Johannes Hötter, Christian Warmuth

openHPI

### Zwiespalt: Datensparsamkeit vs. Performance







#### Art. 5 DSGVO

# Grundsätze für die Verarbeitung personenbezogener Daten

- (1) Personenbezogene Daten müssen
  - a) auf rechtmäßige Weise, nach Treu und Glauben und in einer für die betroffene Person nachvollziehbaren Weise verarbeitet werden ("Rechtmäßigkeit, Verarbeitung nach Treu und Glauben, Transparenz");
  - b) für festgelegte, eindeutige und legitime Zwecke erhoben werden und dürfen nicht in einer mit diesen Zwecken nicht zu vereinbarenden Weise weiterverarbeitet werden; eine Weiterverarbeitung für im öffentlichen Interesse liegende Archivzwecke, für wissenschaftliche oder historische Forschungszwecke oder für statistische Zwecke gilt gemäß Artikel 89 Absatz 1 nicht als unvereinbar mit den ursprünglichen Zwecken ("Zweckbindung");
  - c) dem Zweck angemessen und erheblich sowie auf das für die Zwecke der Verarbeitung notwendige Maß beschränkt sein ("Datenminimierung");
  - d) sachlich richtig und erforderlichenfalls auf dem neuesten Stand sein; es sind alle angemessenen Maßnahmen zu treffen, damit personenbezogene Daten, die im Hinblick auf die Zwecke ihrer Verarbeitung unrichtig sind, unverzüglich gelöscht oder berichtigt werden ("Richtigkeit");

mehr Trainingsdaten = bessere Ergebnisse

Copyright der Trainingsdaten

Johannes Hötter, Christian Warmuth

openHPI

Quelle: https://dsgvo-gesetz.de/art-5-dsgvo/





Bundesministerium für Bildung und Forschung



- openHPI: ChatGPT: Was bedeutet generative KI für unsere Gesellschaft? -

# Copyright der Trainingsdaten

Johannes Hötter Christian Warmuth